




Efficient Computing / PC 2

Miniaturisierung

T. F. Bosse, R. J. Domogalla, H. M. Bucker
Lehrstuhl für Advanced Computing, FSU Jena

Rechtlicher Hinweis

Diese Vorlesung ist urheberrechtlich geschützt und darf nur im Rahmen von Lehrveranstaltungen der Friedrich-Schiller-Universität Jena verwendet werden. Eine Nutzung durch Verbreitung oder Veröffentlichung dieses Materials — auch in Auszügen — ist strengstens untersagt und wird die Geltendmachung von Unterlassungs- und Schadenersatzansprüchen durch die Friedrich-Schiller-Universität Jena zur Folge haben.

Miniaturisierung

Warum ist Miniaturisierung überhaupt möglich?

Was ist der Einfluss auf Performance bezüglich der Laufzeit und elektrischer Leistung?

Auf der Ebene der Bit-Darstellung

- Informationen werden durch Bits codiert.
- Bits sind mathematisch definiert, können physikalisch unterschiedlich repräsentiert werden.
- *Beispiel:*
 - Wassertank ist voll $\hat{=}$ 1 $\hat{=}$ ■
 - Wassertank ist leer $\hat{=}$ 0 $\hat{=}$ □
- Wie schnell erfolgt ein Bitwechsel also Befüllen oder Entleeren des Wassertanks?

Auf der Ebene der Bit-Darstellung

Wie schnell erfolgt ein Bitwechsel also Befüllen oder Entleeren des Tanks?

- $V \triangleq$ Volumen des Wassertanks
- $Q := V/T \triangleq$ Volume Flow Rate (beschreibt wieviel Volumen V gelangt innerhalb einer Zeit T durch eine spezifische Fläche)

Zeit für Bitwechsel in bezgl. Volumen V ist: $T = V/Q$.

Beispiel: Ein Fass mit einem Volumen $V = 450l$ und einem Ausfluss mit einer Volume Flow rate von $Q = 30l/min$ benötigt eine Viertelstunde zum Entleeren.

Auf der Ebene der Bit-Darstellung

Eine Verkleinerung des Tanks von einem großen Volumen V zu einem Tank mit kleinerem Volumen $v=\alpha V$ mit $0 \leq \alpha \leq 1$ mit gleich bleibender Volume Flow Rate Q verringert die Zeit zum Befüllen/Entleeren:

$$t = v/Q = (\alpha V)/Q = \alpha(V/Q) = \alpha T$$

D. h., eine Verkleinerung des Volumens um einen Faktor α verringert die Zeit für den „Bitwechsel“ ebenfalls um den Faktor α .

Kleiner physikalische Volumina verkleinern die Zeit für Bitwechsel. Da Information keine physikalische Größe besitzt kann herunter skaliert werden.

Auf der Ebene von Computern

Beobachtung: Information muss in einem Rechner von einem Ort A zu einem Ort B übertragen werden.

Ein einfaches Modell zur Übertragung von Informationen durch elektromagnetische Wellen ist ein perfekter Übertragungskanal in Form eines Koaxialkabels.

Hinweis: In der Realität wird Information in Schaltkreisen nicht durch Koaxialkabel übertragen. Allerdings sind die zugrundeliegenden Phänomene ähnlich.

Physikalisches Modell

Information kann physikalisch durch Spannung repräsentiert werden.

Beispiel: Koaxialkabel

- $U \triangleq$ Spannung
- $Q \triangleq$ Elektrische Ladung
- $C \triangleq$ Kapazität



Русский Измайлов via
Wikimedia Commons


Dabei gilt: $Q = C * U$, wobei C eine Materialeigenschaft ist.

Änderungen in der Information (repräsentiert durch U) bei gleichem Material entsprechen daher Änderung der Ladung Q .

Kapazität vs. Kabellänge

Wie schnell kann Information übertragen werden?


Kenntnis der Kapazität C ist wichtig. Für zyklische Kondensatoren mit Dielektrizitätskonstante ε (Materialeigenschaft) und folgender Geometrie:



gilt: $C = \frac{2\pi\varepsilon L}{\ln \frac{R}{r}} \sim L$, d. h. die Kapazität ist proportional zur Länge.

Längste Entfernung im Computer

Clock Cycle Time eines Rechners muss größer sein, als die maximale Zeit, die man für irgendeine Informationsübertragung benötigt. Da diese Zeit abhängig von Länge ist, betrachte jeweils die maximale Entfernung zwischen zwei Orten A und B in einem Computer.



Vereinfachte Annahme: Computer ist ein Würfel mit Kantenlänge L und Volumen $V = L^3$.

Die längste Entfernung in einem Würfel beträgt $3L = 3V^{1/3}$.

Clock Cycle Time

Sei g die Geschwindigkeit zur Informationsübertragung in einem Rechner. Dann gilt für die minimale Clock Cycle Time

$$t_{min} \geq \frac{\text{max. Entfernung}}{\text{Geschwindigkeit}} = \frac{3V^{1/3}}{g} = \frac{3L}{g} \sim L$$

für die maximale Clock Rate (Taktrate) gilt

$$f_{max} \leq \frac{g}{3V^{1/3}} \sim \frac{1}{L}.$$

D. h., die Taktzeiten und Frequenzen werden durch die Länge bestimmt.


Realitätscheck

für Miniaturisierung auf Ebene von Computern:


	Jahr	Volumen	Taktzeiten
ENIAC	1945	65 m^3	$200 \times 10^{-6} \text{ sec}$
iPhone	2018	$12.5 \times 10^{-6} \text{ m}^3$	$0.4 \times 10^{-9} \text{ sec}$
<u>ENIAC</u> iPhone		5×10^6	5×10^5

Quelle: A. Chien, Computer Architecture for Scientists, Seite 58, Tabelle. 3.1

Fazit: Kleinere Rechner sind schneller und erlauben auf gleichem Platz mehr Speicher/Transistoren/...




Unknown Author via Wikimedia Commons



Unidentified U.S. Army photographer via Wikimedia Commons

Zeitliche Entwicklung der Transistoren Anzahl



Elektrische Leistung

- Für die elektrische Arbeit W bei Verschiebung einer Ladung Q zwischen zwei Punkten, zwischen denen die Spannung U besteht, gilt
$$W = Q * U.$$
- Sei C die Kapazität, dann ist die Ladung ist proportional zur Spannung
$$Q = C * U.$$
- Die elektrische Leistung P bezeichnet die vollbrachte Arbeit W pro Zeit T (bzw. bezüglich Frequenz f) und ist gegeben durch

$$P = \frac{W}{T} = W * f = Q * U * f = C * U^2 * f$$

Ziel: Elektrische Leistung konstant halten über Computer Generationen.
(Erinnerung $C \approx L$ und $f \approx 1/L$)

Miniaturisierung von Gen. 1 zu Gen. 2

- Reduzieren der Länge um Faktor $\alpha < 1$

$$L_1 \rightarrow L_2 = \alpha L_1.$$

- Reduzieren der Kapazität

$$C_1 \rightarrow C_2 = \alpha C_1.$$

- Erhöhen der Frequenz

$$f_1 \rightarrow f_2 = \frac{f_1}{\alpha}.$$

Durch die Miniaturisierung kann die Anzahl der Bauelemente von B_1 auf kB_1 Elemente erhöht werden bei gleicher Chip-Fläche, falls gleichzeitig die Spannung um einen Faktor $\beta < 1$ reduziert wird

$$U_1 \rightarrow U_2 = \beta U_1.$$

Konstante Leistung über Generationen

- Leistung für den Computer der Gen. 1 ist gegeben durch

$$P_1 = C_1 * U_1^2 * f_1.$$

- Leistung für den Computer der Gen. 2 ist gegeben durch

$$\begin{aligned} P_2 &= k * C_2 * U_2^2 * f_2 = k * \alpha * C_1 * (\beta U_1)^2 * \frac{f_1}{\alpha} \\ &= k * C_1 * (\beta U_1)^2 * f_1 = k * \beta^2 * P_1. \end{aligned}$$

- Für gleiche Leistung ($k * \beta^2 = 1$) muss bei Verdopplung der Anzahl von Transistoren ($k = 2$) daher folgen $\beta^2 = \frac{1}{2} \rightarrow \beta \approx 0.7$

Fazit: Dennart Scalling „kleine Rechner sind Energie-effizient“!


Grenzen der Miniaturisierung

Das Dennart Scaling endete ca. 2005, weil zu kleine Transistoren fortlaufen Leistung benötigen, auch wenn sie nicht schalten.

Im Fall sogenannter „*leaky*“ Transistoren gelten vorherige Formeln nicht mehr, was zu einer Stagnation der Taktfrequenz bei einem maximalen Wert von 4GHz führte.


Konsequenz: Weitere Miniaturisierung erlaubt es nicht, die Taktfrequenz zu erhöhen. Seitdem kann Performance-Erhöhung nur noch unter Aufgabe der seriellen Abstraktion erfolgen.

Zeitliche Entwicklung der Taktfrequenz



Auf der Ebene von Speichern

von-Neumann-Architektur: Rechner aufgeteilt in CPU und Memory.



- ✓ ISA ist geeignete Abstraktion zur Trennung, weil Zugriff auf Memory nur durch Load-Store-Befehle folgt.
- ✓ Technologie-Entwicklung kann (weitgehend) unabhängig in CPU und Memory separat vorgenommen werden
- ✓ Miniaturisierung erfolgt unabhängig voneinander
- ❖ Begrenzung der Rate des Speicherzugriffs „von-Neumann-Flaschenhals“